

MANUAL OPERATIVO DEL SISTEMA RAG Y AGENTE IA AUREA

Versión 2.0

Última actualización

Julio de 2026

1. OBJETIVO

Documentar la arquitectura, funcionamiento, despliegue y operación del Agente IA de AUREA basado en tecnologías de Inteligencia Artificial Generativa y Retrieval-Augmented Generation (RAG).

Este documento sirve como referencia para administradores, desarrolladores y evaluadores del proyecto.

2. DESCRIPCIÓN GENERAL DEL SISTEMA

El Agente IA de AUREA es un asistente virtual diseñado para responder consultas relacionadas con:

- Productos de belleza.
- Maquillaje.
- Skincare.
- Envíos.
- Pagos.
- Garantías.
- Devoluciones.
- Atención al cliente.

El sistema utiliza una arquitectura RAG (Retrieval-Augmented Generation), permitiendo responder preguntas utilizando únicamente información oficial almacenada en la base documental de AUREA.

3. ARQUITECTURA GENERAL

Componentes Principales

Usuario

Persona que interactúa con el sistema.

Aplicación Web

Interfaz desarrollada en Streamlit.

Motor RAG

Responsable de recuperar información relevante.

Base Vectorial

Repositorio semántico de documentos indexados.

Modelo de IA

Genera respuestas utilizando el contexto recuperado.

Base Documental

Conjunto de documentos PDF oficiales de AUREA.

4. DOCUMENTOS DE CONOCIMIENTO

La base documental utilizada por el sistema incluye:

Documento 1

Manual Maestro de Marca AUREA.

Documento 2

Política de Envíos.

Documento 3

Política de Devoluciones y Reembolsos.

Documento 4

Manual de Pagos PSE.

Documento 5

Manual de Garantías.

Documento 6

FAQ de Belleza y Skincare.

Documento 7

Manual de Atención al Cliente y Operación del Agente IA.

Documento 8

Catálogo Maestro de Productos.

Documento 9

Base de Casos Reales de Atención al Cliente.

5. FLUJO DE FUNCIONAMIENTO

Paso 1

El usuario realiza una pregunta.

Ejemplo:

"¿Cómo solicito una garantía?"

Paso 2

El sistema interpreta la intención de la consulta.

Paso 3

Se realiza una búsqueda semántica en la base documental.

Paso 4

Se recuperan los fragmentos más relevantes.

Paso 5

El contexto recuperado es enviado al modelo de IA.

Paso 6

El sistema genera una respuesta fundamentada en la documentación oficial.

6. RECUPERACIÓN DE INFORMACIÓN (RAG)

Objetivo

Permitir que el modelo responda utilizando información específica de AUREA.

Proceso

Indexación

Carga de documentos PDF.

Fragmentación

División de documentos en bloques de texto.

Embeddings

Transformación de bloques en vectores semánticos.

Almacenamiento

Registro de embeddings en ChromaDB.

Recuperación

Búsqueda de información relevante según la consulta.

7. INFRAESTRUCTURA DEL SISTEMA

Entorno de Desarrollo

Google Colab

Utilizado para:

- Desarrollo inicial.
 - Procesamiento de documentos.
 - Pruebas de embeddings.
 - Validación del sistema RAG.
-

Entorno de Producción

Streamlit Community Cloud

Utilizado para:

- Publicación del agente.
 - Acceso público.
 - Interfaz de usuario.
-

Almacenamiento Documental

Archivos PDF oficiales de AUREA.

Base Vectorial

ChromaDB

Funciones:

- Almacenar embeddings.
- Realizar búsquedas semánticas.
- Recuperar contexto relevante.

8. TECNOLOGÍAS UTILIZADAS

Modelo de IA

OpenAI GPT

Responsable de generar respuestas naturales utilizando el contexto recuperado.

Embeddings

OpenAI Embeddings

Utilizados para representar semánticamente los documentos.

Framework RAG

LangChain

Responsable de:

- Gestionar documentos.
 - Recuperar contexto.
 - Integrar el modelo de IA.
-

Base Vectorial

ChromaDB

Almacenamiento de vectores y búsqueda semántica.

Frontend

Streamlit

Interfaz conversacional para los usuarios.

9. PROMPT DEL SISTEMA

El agente deberá:

- Responder únicamente utilizando información documentada.
 - Evitar inventar información.
 - Mantener el tono de AUREA.
 - Escalar consultas fuera de la base documental.
 - No proporcionar asesoría médica.
-

10. CONTROL DE ALUCINACIONES

Para minimizar errores:

Regla 1

Utilizar únicamente información recuperada.

Regla 2

No responder con información no documentada.

Regla 3

Indicar cuando no exista información suficiente.

Regla 4

Escalar casos complejos.

11. ESCALAMIENTO

El agente deberá escalar:

- Casos legales.
 - Casos médicos.
 - Solicitudes de atención humana.
 - Reclamos complejos.
 - Casos no documentados.
-

12. MÉTRICAS DEL SISTEMA

Precisión

Calidad de las respuestas generadas.

Tiempo de Respuesta

Velocidad de atención.

Recuperación de Información

Pertinencia de los documentos encontrados.

Satisfacción del Usuario

Nivel de satisfacción reportado por los usuarios.

13. SEGURIDAD

El sistema deberá:

- Proteger datos personales.
 - Utilizar conexiones seguras.
 - No almacenar credenciales bancarias.
 - Respetar las políticas de privacidad.
-

14. MANTENIMIENTO

La base documental deberá actualizarse cuando existan cambios en:

- Productos.
 - Políticas.
 - Garantías.
 - Pagos.
 - Procedimientos internos.
-

15. VERSIONAMIENTO

Cada documento deberá incluir:

- Número de versión.
 - Fecha de actualización.
 - Responsable del cambio.
-

16. PROCEDIMIENTO DE ACTUALIZACIÓN

Paso 1

Actualizar documento fuente.

Paso 2

Regenerar embeddings.

Paso 3

Actualizar ChromaDB.

Paso 4

Realizar pruebas funcionales.

Paso 5

Publicar la nueva versión.

17. CASOS DE USO

Consulta de Productos

"¿Qué producto recomiendan para piel grasa?"

Consulta de Envíos

"¿Cuándo llegará mi pedido?"

Consulta de Garantías

"Mi producto llegó dañado."

Consulta de Pagos

"Mi pago fue rechazado."

Consulta de Devoluciones

"Quiero solicitar un reembolso."

18. BENEFICIOS DEL SISTEMA

- Atención 24 horas.
 - Respuestas consistentes.
 - Acceso inmediato a la información.
 - Reducción de carga operativa.
 - Escalabilidad futura.
-

19. DESPLIEGUE DEL AGENTE IA

Objetivo

Publicar el asistente virtual de AUREA para que pueda ser utilizado desde Internet por clientes y evaluadores del proyecto.

Arquitectura de Producción

Usuario

↓

Aplicación Streamlit

↓

Motor RAG

↓

ChromaDB

↓

OpenAI GPT

↓

Respuesta al Usuario

Componentes

Frontend

Streamlit.

Motor RAG

LangChain.

Base Vectorial

ChromaDB.

Modelo de IA

OpenAI GPT.

Acceso Público

El sistema estará disponible mediante una URL pública proporcionada por Streamlit Community Cloud.

Ejemplo:

<https://aurea-assistant.streamlit.app>

Ventajas del Despliegue

- Fácil acceso.
 - Bajo costo.
 - Implementación rápida.
 - Disponibilidad pública.
-

Escalabilidad Futura

La arquitectura permitirá migrar posteriormente hacia plataformas empresariales como:

- Oracle Cloud Infrastructure (OCI).
- Amazon Web Services (AWS).
- Microsoft Azure.
- Google Cloud Platform (GCP).

Sin modificar significativamente la lógica del sistema.

20. CONCLUSIÓN

El Agente IA de AUREA implementa una arquitectura RAG basada en OpenAI, LangChain, ChromaDB y Streamlit. La solución permite responder consultas utilizando exclusivamente información oficial de la empresa, garantizando respuestas consistentes, precisas y alineadas con las políticas corporativas. La aplicación se encuentra diseñada para ser desplegada públicamente mediante Streamlit Community Cloud y preparada para futuras migraciones hacia entornos empresariales de nube.

AUREA Colombia

Manual Operativo del Sistema RAG y Agente IA

Versión 2.0